HCMUTE

FIT HCM-UTE

BÁO CÁO CUỐI KỲ MÔN

ỨNG DỤNG PHÂN TÍCH DỮ LIỆU LỚN TRONG KINH DOANH (BIG DATA)

Đề tài: Phân tích hành vi người tiêu dùng và phản hồi khách hàng đối với thương hiệu mỹ phẩm Cocoon trên hai nền tảng Shopee và Hasaki



GVHD: TS. Trần Quang Khải

Sinh viên thực hiện: Nhóm 18

QUY TRÌNH THU THẬP DỮ LIỆU HASAKI & SHOPEE

HASAKI.VN | GỌI API JSON

01 Khám phá API

Chrome → F12 → Network → Fetch/XHR; tìm Request URL và cấu trúc JSON.

02 Thu thập dữ liệu

API danhsách SP: size=10.000; API review: phân trang 50 đánhgiá/lần.

03 Chạy JavaScript

Chrome Console; cấu hình BRAND=cocoon, DELAY=500 ms, PAGE=50.

04 Xuất CSV

Ghép metadata sản phẩm + review; CSV 13 cột, mã hóa UTF-8 BOM.

Kết quả

207
Sản phẩm

2.835
Dòng dữ liệu

13 cột
CSV

SHOPEE MALL INSTANT DATA SCRAPER

01 Truy cập danh mục sản phẩm

Mở từng đường link trong 31 danh mục sản phẩm của gian hàng Cocoon trên Shopee Mall.

02 Kích hoạt công cụ Instant Data Scraper

Sử dụng tiện ích Instant Data Scraper để tự động nhận diện khung đánh giá của khách hàng.

03 Tự động chuyển trang

Thiết lập tính năng tự động chuyển sang trang tiếp theo để thu thập các đánh giá sản phẩm.

04 Xuất dữ liệu Excel

Sau khi hoàn tất quá trình thu thập, dữ liệu được xuất thành các file Excel riêng biệt.

Kết quả

84
File Excel thô

31
Danh mục

Đặc điểm và hạn chế của dữ liệu thô

- Thiếu thông tin sản phẩm
- Tên cột bị mã hóa HTML
- Dữ liệu chưa đồng nhất

QUY TRÌNH LÀM SẠCH DỮ LIỆU HASAKI

FILE GỐC 2.835 dòng × 13 cột → **TÁCH THÀNH 2 BẢNG**

BẢNG SẢN PHẨM | products_hasaki

01 Tách và khử trùng lặp
Lấy 9 cột đầu; bỏ trùng theo Mã SP → 207 sản phẩm.

02 Chuẩn hóa trường dữ liệu
Cắt khoảng trắng tên; xử lý giá gốc trống (1 SP điền bằng giá bán).

03 Lọc sản phẩm
Giữ sản phẩm có lượt bán 30 ngày > 0 VÀ có đánh giá: 207 → 84.

04 Bổ sung 4 cột tính toán
Category; Trang_Thai_Mau; Doanh_Thu_Niem_Yet; % Chênh lệch giá.

BẢNG ĐÁNH GIÁ | Reviews_Hasaki

01 Loại dòng không có review
Bỏ 98 dòng trống; còn 2.737 dòng.

02 Giữ review thuộc 84 sản phẩm
Còn 2.132 dòng trước khi tiếp tục lọc nội dung.

03 Khử trùng & lọc review
Xử lý 46 dòng trùng hoàn toàn; bỏ review không nội dung, rao bán và vô nghĩa.

04 Chuẩn hóa & gắn cờ
Xóa
, emoji, khoảng trắng, thêm Review ngắn và Chưa mua hàng.

Kết quả

84
Sản phẩm

737
Đánh giá

4,89/5
Điểm trung bình

TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU (DATA CLEANING)

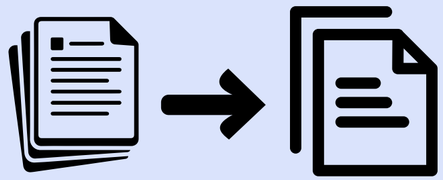
Ứng dụng Python (Pandas) để hợp nhất, xử lý và chuẩn hóa dữ liệu đánh giá sản phẩm Cocoon.

the cocoon ORIGINAL VIETNAM

Quy trình làm sạch dữ liệu

01 Hợp nhất dữ liệu

- Gộp 84 file Excel thô thành 1 file dữ liệu thống nhất.
- Chuẩn hóa tên cột và bổ sung Metadata sản phẩm.



02 Chuẩn hóa ngày Review

- Loại bỏ thông tin phân loại hàng và giờ phút.
- Chuyển ngày đánh giá về định dạng YYYY-MM-DD.

Trước	Sau
2024-05-12 14:30 – Phân loại hàng:	12/5/2024

03 Quy đổi lượt bán

- Chuyển ký tự k/K thành số nguyên.
- Ví dụ: 81.8k → 81.800.

Trước	Sau
81.8k	81800

04 Tính doanh thu 30 ngày

- Áp dụng công thức:

Doanh thu 30 ngày = Lượt bán*Giá bán

Lượt bán	Giá bán	Doanh thu
81.800	150.000đ	12.270.000.000đ

05 Làm sạch văn bản và khử trùng lặp

- Xóa ký tự xuống dòng, khoảng trắng dư thừa và xử lý teencode.
- Loại bỏ review trùng lặp và review rác.
- Tạo mã định danh duy nhất (rid).

Trước	Sau
Sản phẩm tốt \n Giao hàng	Sản phẩm tốt Giao hàng

Kiểm soát chất lượng dữ liệu

Sử dụng Pivot Table

Đối soát số lượng review theo từng danh mục sản phẩm.

Dùng AutoFilter

Kiểm tra toàn bộ 13 trường dữ liệu.

Kiểm tra dữ liệu

Đối chiếu số sao từ 1–5 và trạng thái mua hàng Có/Không.

Chuẩn hóa định dạng

Định dạng tiền tệ và nội dung review trên Excel.

Kiểm soát chất lượng dữ liệu

✓ **6.420**
Dòng review sạch

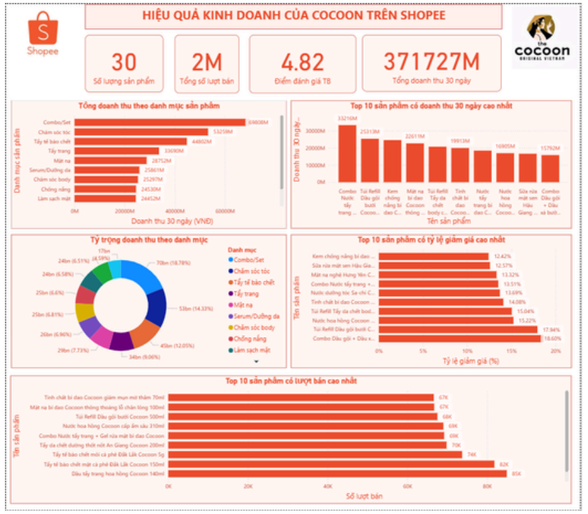
✓ **0%**
Tỷ lệ ô trống (NaN)

✓ **13**
Trường dữ liệu chuẩn hóa

TRỰC QUAN HÓA DỮ LIỆU TRÊN POWER BI

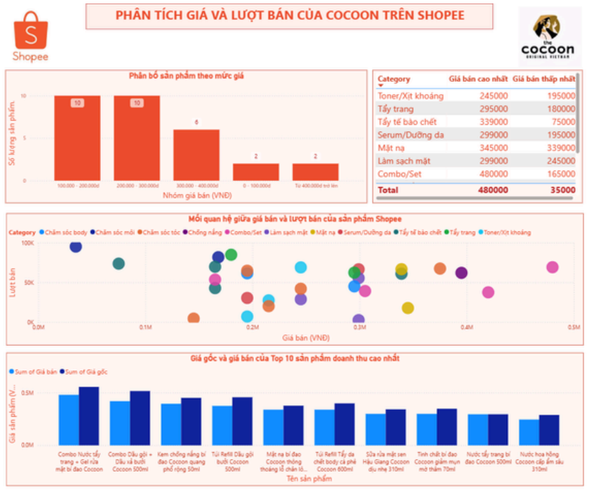
1. DASHBOARD TỔNG QUAN COCOON – SHOPEE

- Dữ liệu: tên sản phẩm, danh mục, giá bán, lượt bán, doanh thu 30 ngày, tỷ lệ giảm giá, điểm đánh giá.
- Card: số sản phẩm (đếm), doanh thu (tổng), điểm đánh giá (trung bình), lượt bán (tổng phù hợp).
- Biểu đồ thanh/cột: lượt bán và doanh thu theo sản phẩm; so sánh sản phẩm bán nhiều với sản phẩm tạo doanh thu cao.



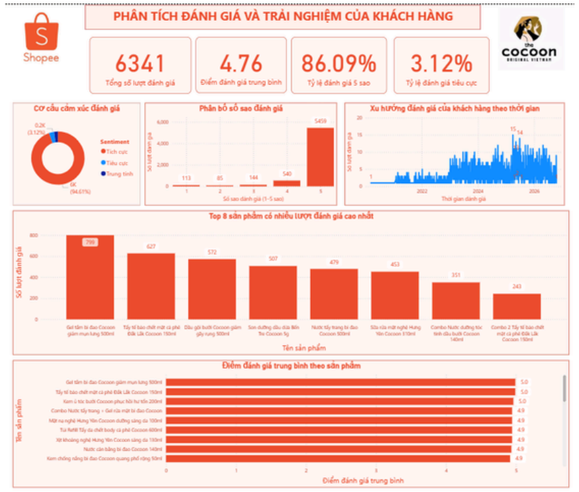
2. DASHBOARD PHÂN TÍCH SẢN PHẨM COCOON– SHOPEE

- Scatter: giá bán (X) = lượt bán (Y), nhận diện sản phẩm/danh mục; chỉ phân ánh mối liên hệ, không chứng minh nhân quả.
- Cột ghép: so sánh giá gốc và giá bán từng sản phẩm; cần chọn phép tổng hợp phù hợp, tránh cộng các mức giá.
- Cột theo nhóm giá: đếm sẽ sản phẩm trong từng khoảng giá.
- Bảng: giá bán cao nhất và thấp nhất theo danh mục.



3. DASHBOARD PHÂN TÍCH ĐÁNH GIÁ COCOON – SHOPEE

- Scatter: danh mục, trạng thái màu, tên sản phẩm; biểu đồ tự cập nhật theo lựa chọn.
- Thanh xếp hạng doanh thu: 30 ngày theo sản phẩm; có thể dùng Top N để tập trung sản phẩm nổi bật.
- So sánh giá bán trung bình với giá gốc trung bình.
- Scatter: giá bán + lượt bán, bổ sung điểm đánh giá; cột lượt bán theo danh mục.



4. DÁNH SÁCH MIN - MAX COCOON – SHOPEE

- Chọn chỉ tiêu cần thống kê (ví dụ: giá bán, lượt bán, doanh thu, điểm đánh giá).
- Dùng Table với cột Tên chỉ tiêu – Max – Min; áp dụng MAX/MIN và định dạng đơn vị phù hợp.
- Đối chiếu kết quả với dữ liệu nguồn hoặc sắp xếp trường tương ứng.



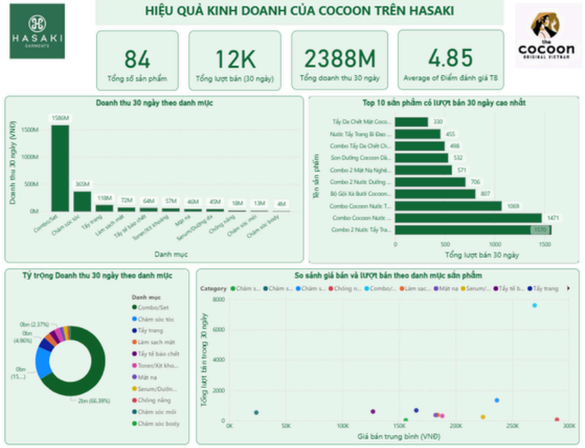
Chỉ tiêu	Max	Min
% Giảm giá	18.60%	0.00%
Điểm đánh giá TB	5.0	4.0
Doanh thu 30 ngày	33,216,000,000	652,500,000
Giá bán	480,000	35,000
Giá gốc	555,000	35,000
Lượt bán	95,200	2,600
Tổng lượt đánh giá	32,500	742

Chỉ tiêu	Max	Min
Số lượng review	6,341	6,341
Số review tích cực	799	105
Số review tiêu cực	78	17
Số sao đánh giá	5	1

TRỰC QUAN HÓA DỮ LIỆU TRÊN POWER BI

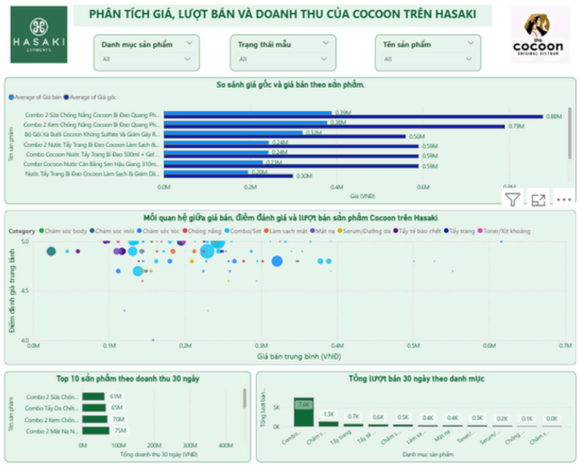
1. DASHBOARD TỔNG QUAN COCOON – HASAKI

- Dữ liệu: tên sản phẩm, danh mục, giá bán/giá gốc, lượt bán 30 ngày, doanh thu 30 ngày, điểm đánh giá.
- Card: tổng lượt bán, tổng doanh thu, số sản phẩm, điểm đánh giá trung bình.
- Donut + biểu đồ doanh thu theo danh mục; thanh so sánh lượt bán theo sản phẩm; Scatter xem giá bán × lượt bán.



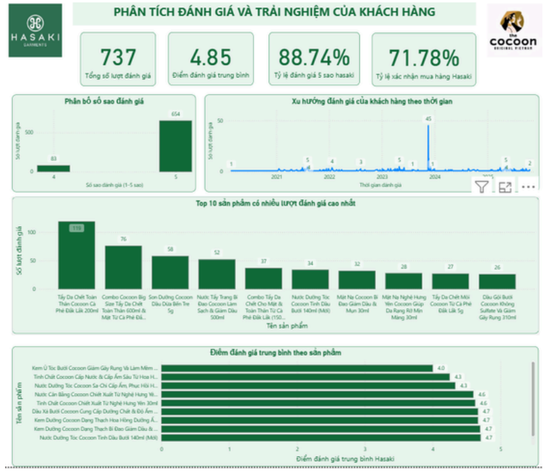
2. DASHBOARD PHÂN TÍCH SẢN PHẨM COCOON– HASAKI

- Slicer: danh mục, trạng thái màu, tên sản phẩm; biểu đồ tự cập nhật theo lựa chọn.
- Thanh xếp hạng doanh thu 30 ngày theo sản phẩm; có thể dùng Top N để tập trung sản phẩm nổi bật.
- So sánh giá bán trung bình với giá gốc trung bình.
- Scatter: giá bán × lượt bán, bổ sung điểm đánh giá; cột lượt bán theo danh mục.



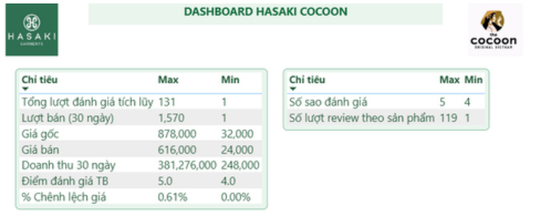
3. DASHBOARD PHÂN TÍCH ĐÁNH GIÁ COCOON – HASAKI

- Dữ liệu đánh giá đã làm sạch; kiểm tra mã sản phẩm giữa bảng đánh giá và bảng sản phẩm.
- Card: điểm đánh giá trung bình; tổng lượt đánh giá; tỷ lệ 5 sao; tỷ lệ xác nhận mua hàng.
- Cột: số lượng đánh giá theo số sao; đường: số lượt đánh giá theo thời gian.
- Cột/thanh: tổng lượt đánh giá và điểm trung bình theo sản phẩm.
- Đối chiếu Card với biểu đồ; rà soát thiếu sao, thiếu ngày và mã sản phẩm không khớp.



4. DANH SÁCH MIN - MAX COCOON – HASAKI

- Thực hiện tương tự trên dữ liệu Hasaki; kiểm tra ô trống, dữ liệu sai định dạng và giá trị không hợp lệ.
- Chuyển trường số từ văn bản sang số trước khi tính.
- Chỉ so sánh hai nền tảng khi định nghĩa trường, đơn vị và thời gian tham chiếu thống nhất.



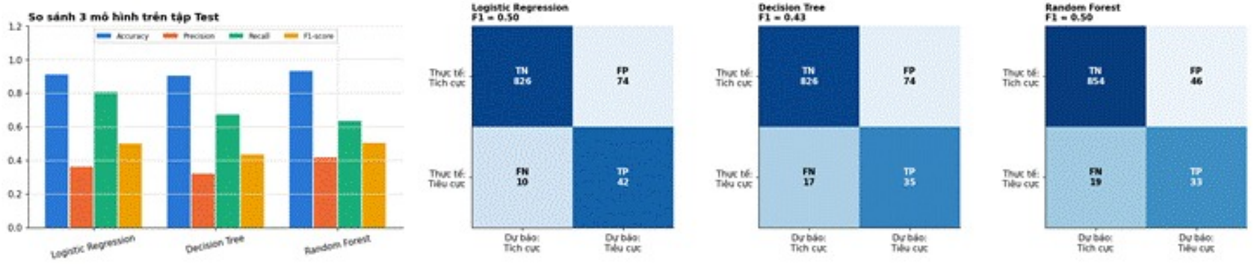
Chỉ tiêu	Max	Min
Tổng lượt đánh giá tích lũy	131	1
Lượt bán (30 ngày)	1,570	1
Giá gốc	878,000	32,000
Giá bán	616,000	24,000
Doanh thu 30 ngày	381,276,000	248,000
Điểm đánh giá TB	5.0	4.0
% Chênh lệch giá	0.61%	0.00%

Chỉ tiêu	Max	Min
Số sao đánh giá	5	4
Số lượt review theo sản phẩm	119	1

Dữ liệu đầu vào và mô hình dự đoán

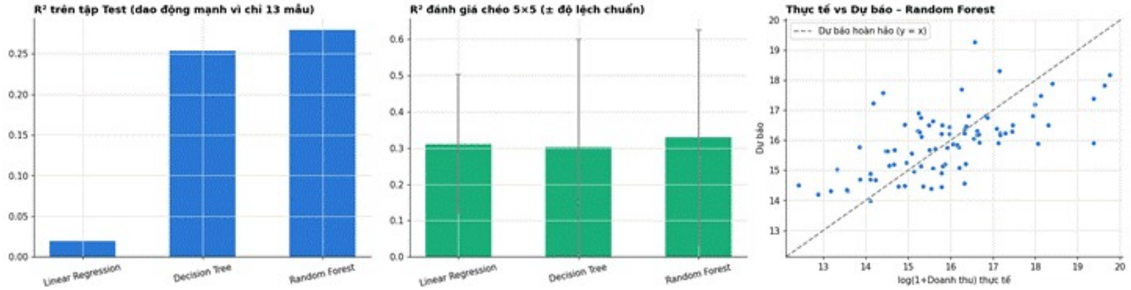
Dữ liệu & quy trình

- 114 sản phẩm: 84 Hasaki, 30 Shopee.
- 7.078 review: 737 Hasaki và 6.341 Shopee.
- Xây dựng 6 mô hình theo các câu hỏi kinh doanh.
- Chia dữ liệu có giám sát: 70% Train – 15% Validation – 15% Test.



Hình - So sánh 3 mô hình phân loại

Hình - KẾT QUẢ HỒI QUY A2



A1 – Phát hiện review tiêu cực

- 114 sản phẩm: 84 Hasaki, 30 Shopee.
- • 7.078 review: 737 Hasaki và 6.341 Shopee.
- • Xây dựng 6 mô hình theo các câu hỏi kinh doanh.
- • Chia dữ liệu có giám sát: 70% Train – 15% Validation – 15% Test.

Ngưỡng cảnh báo A1

• Chọn ngưỡng 0,4 để ưu tiên phát hiện sớm.
• Gắn cờ 143/952 review (15%); Recall 86,5%, Precision 31,5%.
• Nội dung cảnh báo: giao thiếu, hộp không seal, đóng gói sơ sài.

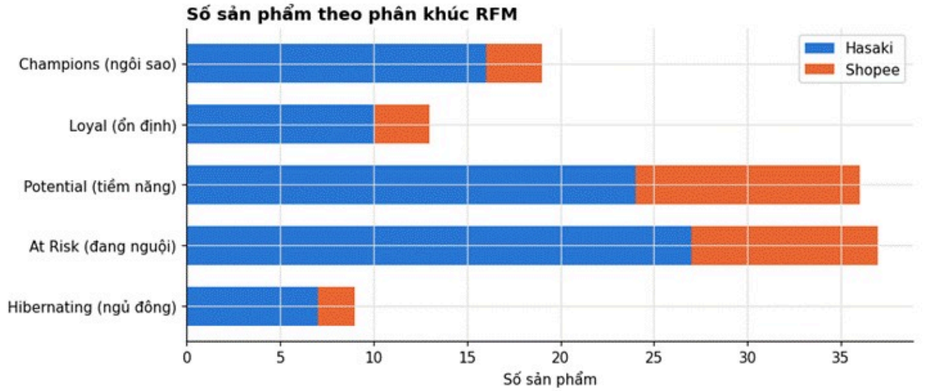
A2 – Dự báo doanh thu Hasaki

Random Forest có R^2 đánh giá chéo 5×5 = 0,329; chỉ nên dùng để xếp hạng và tìm sản phẩm ngoại lệ, chưa đủ tin cậy để dự báo chính xác.

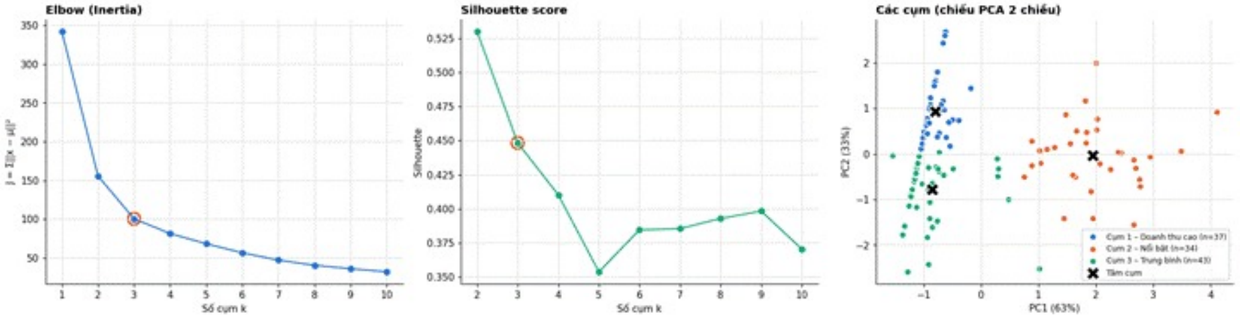
Phân khúc sản phẩm bằng RFM và K-Means

B1 – Phân khúc RFM

- · Do không có mã khách hàng, RFM được tính ở cấp sản phẩm.
- · Recency: số ngày từ review gần nhất.
- · Frequency: số review trong 365 ngày.
- · Monetary: doanh thu 30 ngày; mỗi chỉ số chấm 1–5 theo ngũ phân vị trong từng sàn.



Hình - SỐ SẢN PHẨM THEO PHÂN KHÚC RFM



Hình - ELBOW, SILHOUETTE VÀ PHÂN CỤM PCA

Kết quả RFM đáng chú ý

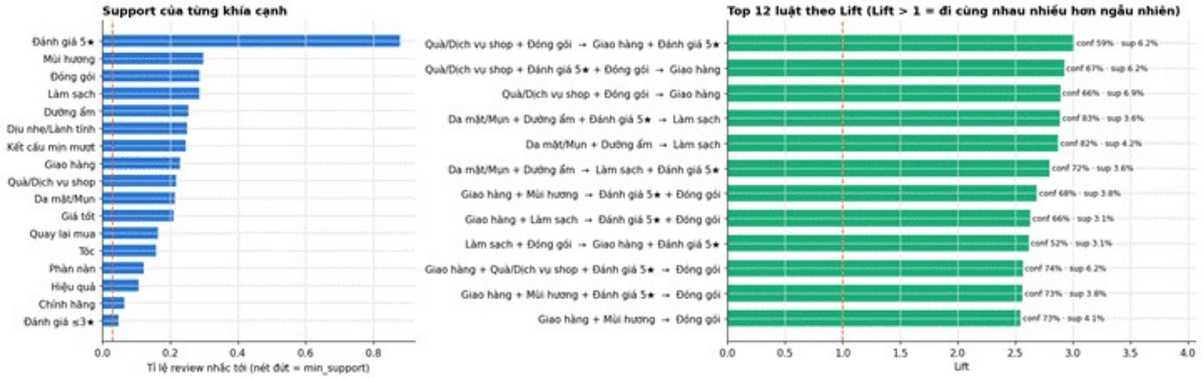
- · 40% sản phẩm ở trạng thái At Risk/nguội trên mỗi sàn.
- · Chỉ 28% (32/114) thuộc Champions hoặc Loyal.
- · Nhóm At Risk có doanh thu trung bình cao nhất (~5,1 tỷ đồng) nên cần rà soát trước khi khuyến mãi.

B2 – K-Means: chọn k = 3; Silhouette = 0,448. Cụm doanh thu cao có 37 sản phẩm, trong đó 29 sản phẩm đồng thời thuộc nhóm At Risk → cần kiểm tra tồn kho, tình trạng kinh doanh và giá so với đối thủ

Khai phá nội dung review và ứng dụng kinh doanh

B3 – Apriori và FP-Growth

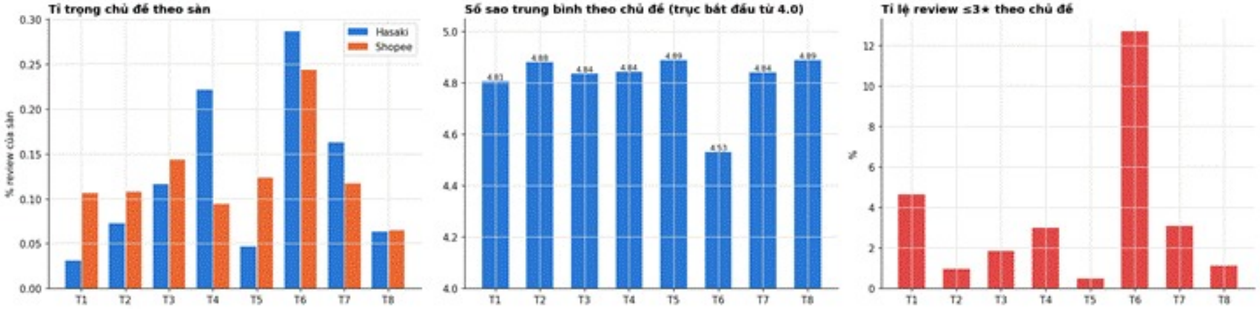
- · 6.716 review được xem như 6.716 “giỏ”, gồm 17 khía cạnh.
- · Hai thuật toán cho cùng 173 tập phổ biến và 148 luật.
- · FP-Growth nhanh hơn: 0,042 giây so với 0,126 giây.
- · Khách thường nhắc cùng lúc giao hàng – đóng gói – dịch vụ shop; làm sạch – dưỡng ẩm.



Hình - SUPPORT VÀ CÁC LUẬT KẾT HỢP CÓ LIFT CAO

C – Topic Modeling (TF-IDF + NMF)

- · Phân tích 6.930 review, chia thành 8 chủ đề.
- · T6 “Chất lượng, giá, ủng hộ shop” có tỷ lệ ≤ 3★ cao nhất: 12,7%.
- · T1 “Giao hàng, đóng gói” có 97% review từ Shopee.
- · Các chủ đề sản phẩm có điểm trung bình cao (4,84–4,89★).



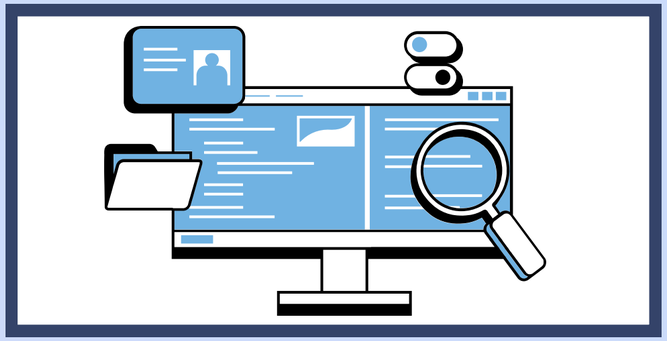
Hình - 8 CHỦ ĐỀ REVIEW TỪ TF-IDF + NMF

ỨNG DỤNG & LƯU Ý: A1 cảnh báo review từ ngưỡng 0,4 để CSKH xử lý hằng ngày; A2 hỗ trợ rà soát sản phẩm theo tháng; RFM/K-Means hỗ trợ kinh doanh – marketing; B3/C định hướng thông điệp “giao nhanh, đóng gói chắc”. Kết quả còn hạn chế do dữ liệu lệch tích cực, quy mô nhỏ và nhãn cảm xúc dựa trên số sao.

Phát triển giao diện hệ thống trên Streamlit

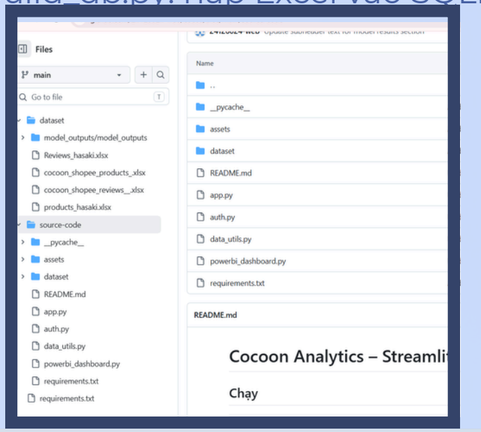
Tổng quan ứng dụng web

- Mục tiêu: Web hóa dữ liệu, dashboard và mô hình để xem online không cần cài phần mềm.
- Công nghệ: Streamlit, Plotly, pandas, GitHub, Streamlit Cloud.
- Quy trình 5 bước: Dữ liệu → Dashboard → Mô hình → Web app → Triển khai.



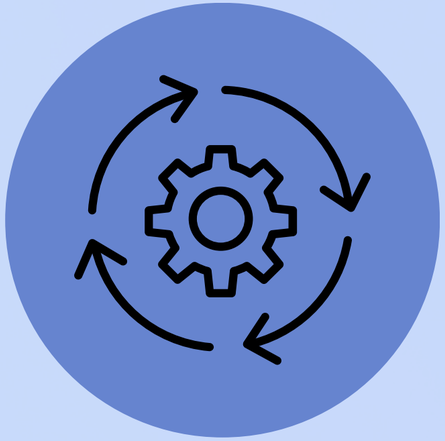
Dữ liệu và cấu trúc mã nguồn

- Dữ liệu: 4 tệp Excel của Shopee và Hasaki, được nạp vào cơ sở dữ liệu SQLite (cocoon.db).
- Hai loại tệp liên kết với nhau bằng cột Mã sản phẩm.
- Mã nguồn chia 4 tệp, mỗi tệp một việc:
  - auth.py: đăng nhập và phân quyền
  - data_utils.py: đọc, làm sạch, ghép dữ liệu
  - app.py: giao diện
  - powerbi_dashboard.py
  - build_db.py: nạp Excel vào SQLite



Xử lý dữ liệu: những quyết định quan trọng

- Chuẩn hóa mã sản phẩm để ghép đúng sản phẩm với review.
- Phân loại hạng mục và dòng sản phẩm tự động từ tên sản phẩm.
- Bảng “một dòng cho mỗi sản phẩm” để doanh thu không bị cộng lặp theo số review.



Đăng nhập và phân quyền

- Phải đăng nhập mới xem được nội dung.
- Hai vai trò:

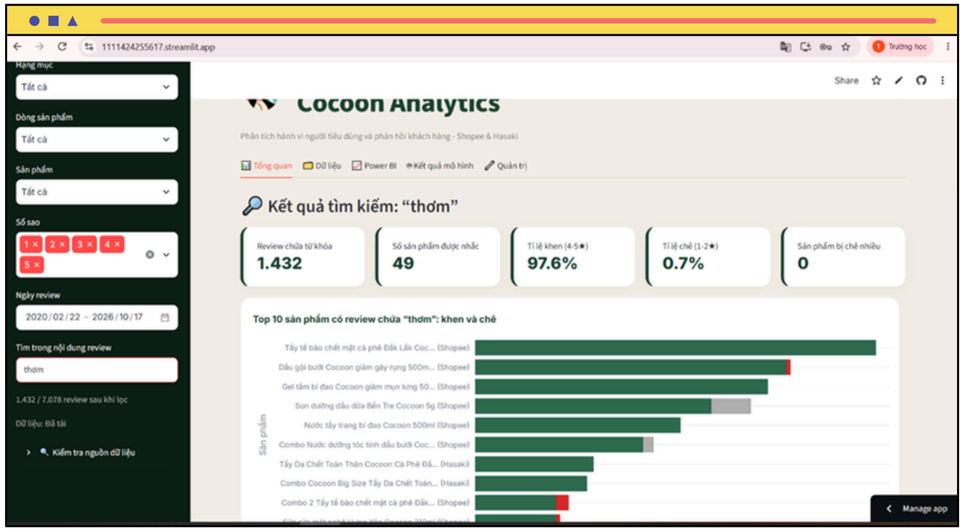
Chức năng	User	Admin
Xem dữ liệu, dashboard, kết quả mô hình	Có	Có
Lọc và tìm kiếm	Có	Có
Tab Quản trị (thêm, sửa, xóa, sao lưu)	Không	Có

- Quản lý dữ liệu (CRUD): thêm, sửa, xóa review. Xóa mềm có nhật ký và khôi phục được. Sao lưu, phục hồi bằng tệp zip.

```
266     prod = du.product_table(df)
267     rv = df[df["Số sao"].notna()]   # chỉ các dòng có review thật
268     tab_names = ["📊 Tổng quan", "📁 Dữ liệu", "📈 Power BI", "🤖 Kết quả mô hình"]
269     if admin:
270         tab_names.append("🔧 Quản trị")
271     tabs = st.tabs(tab_names)
272
```

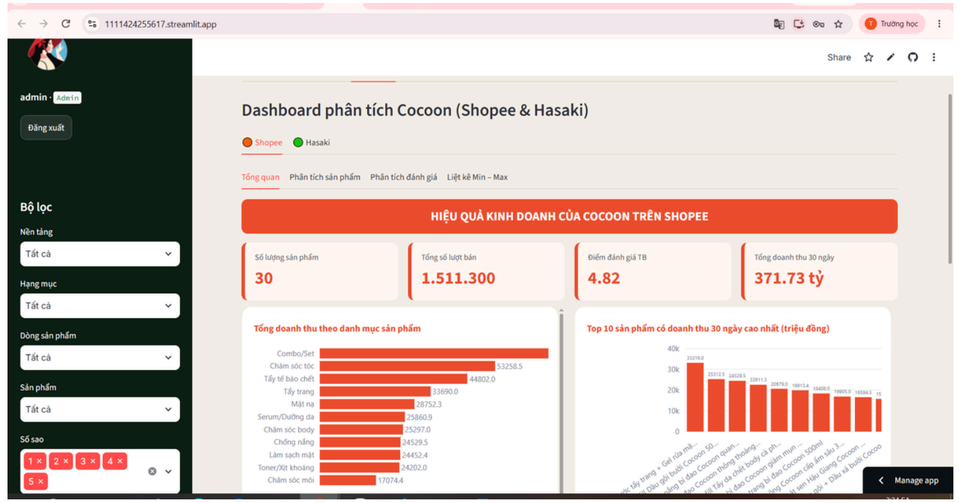
Bộ lọc và tìm kiếm review

- Bộ lọc linh hoạt: 7 bộ lọc đa tầng, tự thu hẹp danh sách liên hoàn.
- Tìm kiếm từ khóa: Thống kê tỷ lệ khen/chê, trực quan hóa bằng biểu đồ cột chồng 3 màu.
- Ứng dụng: Giúp CSKH phát hiện nhanh sự cố đóng gói, mùi hương, giao hàng.



Dashboard Power BI trên web

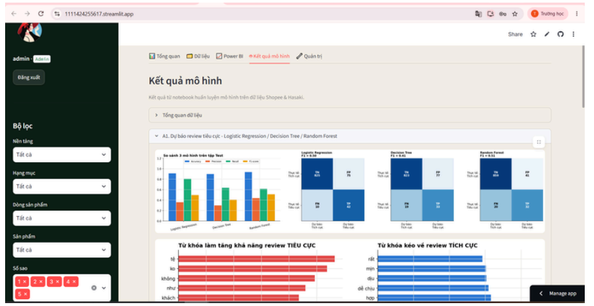
- Vấn đề: Tệp .pbix không chạy trên trình duyệt; dùng Publish to web bị lộ dữ liệu (thiếu phân quyền).
- Giải pháp: Đọc cấu trúc .pbix và dựng lại bằng Python gồm 8 trang (Shopee/Hasaki x 4 trang: Tổng quan, Sản phẩm, Đánh giá, Min-Max).



Kết quả mô hình, kết xuất, triển khai và kiểm thử

- Mô hình & Báo cáo: Tự đọc output Colab (A1–C); xuất CSV/Excel 3 sheet theo đúng bộ lọc,sao lưu và phục hồi dữ liệu.
- Triển khai & Test: Deploy GitHub + Streamlit Cloud (auto-sync 1–2 phút); test thủ công 19 ca khớp Excel gốc.

Định hướng: Định hướng: thêm auto-test, chuyển sang MySQL/PostgreSQL, chạy mô hình trực tiếp trên UI.



https://11114242556l7.streamlit.app